



Sistem Big Data untuk Analisis Estimasi Laba dan Penjualan Saham berbasis Spark dan NoSQL

Erwin Sianturi¹, Fernando Parhusip², Flora Nainggolan³, Febri Sweeta⁴, Dewa Gurusinga⁵

¹ Vokasi, Sarjana Terapan Teknologi Rekayasa Perangkat Lunak, Institut Teknologi Del, Situluama, Indonesia

² Fakultas, Program Studi, Nama Institusi, Kota, Indonesia

Email: ¹erwinsianturi@gmail.com, ²fernandophs@gmail.com, ³floranainggolan100905@gmail.com,

⁴febrisweeta25@gmail.com, ⁵dewagurusinga@gmail.com

Email Penulis Korespondensi: erwinsianturi@gmail.com

Abstrak—Volume data keuangan yang besar membutuhkan sistem pengolahan data yang mampu melakukan proses ingestion, pembersihan, pemrosesan, penyimpanan, dan visualisasi secara terintegrasi. Penelitian ini bertujuan membangun pipeline Big Data untuk menganalisis data earnings estimate dan sales estimate saham menggunakan Apache Spark, SQL, dan NoSQL. Dataset yang digunakan terdiri dari 6.618.616 record dan 9 kolom. Berdasarkan proses exploratory data analysis, ditemukan nilai kosong pada beberapa kolom numerik utama sehingga dilakukan proses cleaning pada kolom estimasi_rata_rata, jumlah_analis, estimasi_tertinggi, dan estimasi_terendah. Setelah proses pembersihan, jumlah data menjadi 5.714.890 record, sehingga 903.726 record dihapus. Apache Spark digunakan untuk menghasilkan ringkasan periode estimasi, saham dengan estimasi rata-rata tertinggi, saham dengan estimasi paling stabil, dan saham dengan pertumbuhan estimasi tertinggi. Hasil processing disimpan ke MySQL/TiDB, kemudian dipindahkan ke MongoDB untuk mendukung visualisasi dashboard Streamlit. Hasil analisis menunjukkan bahwa SNP memiliki rata-rata estimasi tertinggi, FSR memiliki rata-rata pertumbuhan estimasi persentase tertinggi, dan data hasil analisis berhasil tersimpan pada MongoDB tanpa kehilangan dokumen.

Kata Kunci: Apache Spark; Big Data; Estimasi Saham; MongoDB; SQL

Abstract—Large-scale financial data requires an integrated data processing system capable of performing ingestion, cleaning, processing, storage, and visualization. This study aims to develop a Big Data pipeline for analyzing stock earnings estimate and sales estimate data using Apache Spark, SQL, and NoSQL. The dataset consists of 6,618,616 records and 9 columns. Based on the exploratory data analysis process, missing values were identified in several key numerical columns; therefore, data cleaning was performed on average_estimate, number_of_analysts, high_estimate, and low_estimate. After cleaning, the dataset was reduced to 5,714,890 records, meaning that 903,726 records were removed. Apache Spark was used to generate summaries by estimate period, stocks with the highest average estimate, stocks with the most stable estimate, and stocks with the highest estimate growth. The processing results were stored in MySQL/TiDB and then transferred to MongoDB to support visualization using a Streamlit dashboard. The results show that SNP has the highest average estimate, FSR has the highest percentagebased estimate growth, and all processed analytical results were successfully stored in MongoDB without document loss

Keywords: Apache Spark; Big Data; MongoDB; SQL; Stock Estimate

1. PENDAHULUAN

Perkembangan pasar saham menghasilkan data dalam jumlah yang sangat besar dan terus berubah seiring kondisi ekonomi serta dinamika pasar global. Kondisi ini menimbulkan tantangan bagi investor dalam menentukan saham yang memiliki kinerja stabil sekaligus berpotensi tumbuh secara berkelanjutan. Untuk memperoleh informasi tersebut, diperlukan proses pengolahan data yang mampu menganalisis data secara sistematis dan objektif. Selain itu, hasil analisis perlu disimpan pada sistem basis data yang mampu mendukung kebutuhan aplikasi modern dengan performa dan fleksibilitas yang baik. Oleh karena itu, penggunaan arsitektur basis data multimodel yang menggabungkan basis data relasional (SQL) dan basis data dokumen (NoSQL) menjadi solusi yang relevan karena dapat menyediakan integritas data sekaligus fleksibilitas penyimpanan. [1]

Berbagai penelitian telah dilakukan untuk mendukung analisis pasar saham menggunakan teknologi kecerdasan buatan dan komputasi terdistribusi. Penelitian sebelumnya menunjukkan bahwa metode Long Short-Term Memory (LSTM) dapat digunakan untuk memprediksi harga saham jangka pendek dengan hasil yang baik. Penelitian lain menerapkan algoritma Random Forest untuk klasifikasi sektor industri saham dan memperoleh performa yang cukup baik. Di sisi lain, Apache Spark telah dimanfaatkan untuk mengolah data dalam skala besar dan meningkatkan kualitas analisis sentimen pasar. Selain itu, penelitian terkait komputasi Big Data menunjukkan bahwa Apache Spark memiliki performa pemrosesan yang lebih cepat dibandingkan pendekatan konvensional karena memanfaatkan teknologi pemrosesan data di memori. Penelitian lain juga membuktikan bahwa Artificial Neural Network dapat digunakan untuk melakukan prediksi saham berdasarkan data historis. Hasil penelitian tersebut menunjukkan bahwa pemanfaatan algoritma analitik dan teknologi komputasi terdistribusi menjadi pendekatan yang penting dalam analisis pasar saham modern [2].

Meskipun demikian, sebagian besar penelitian sebelumnya masih berfokus pada pengembangan model prediksi dan belum mengintegrasikan proses pengolahan data secara menyeluruh dari tahap analisis hingga penyimpanan hasil ke dalam sistem basis data multimodel [3]. Padahal, pada lingkungan industri, kemampuan memproses data dalam jumlah besar harus diimbangi dengan mekanisme penyimpanan yang efisien agar hasil analisis dapat dimanfaatkan oleh berbagai aplikasi. Oleh karena itu, diperlukan penelitian yang menghubungkan teknologi Big Data dengan sistem penyimpanan yang fleksibel dan terintegrasi [4].




Berdasarkan permasalahan tersebut, penelitian ini mengusulkan penerapan Apache Spark (PySpark) untuk melakukan analisis data estimasi saham dalam skala besar[5]. Fokus penelitian tidak hanya pada prediksi, tetapi juga pada analisis deskriptif dan diagnostik untuk mengidentifikasi saham dengan tingkat stabilitas dan pertumbuhan yang baik berdasarkan data historis [6]. Melalui proses rekayasa fitur dan analisis data terdistribusi, penelitian ini diharapkan dapat menghasilkan informasi yang lebih akurat dan bermanfaat bagi pengambilan keputusan investasi [7].

Kontribusi utama penelitian ini adalah membangun data pipeline yang mampu mengolah data estimasi saham dalam jumlah besar [8]. Tahapan yang dilakukan meliputi pembersihan data, penanganan nilai kosong, deteksi anomali, serta agregasi data untuk menentukan saham terbaik berdasarkan rata-rata valuasi, tingkat stabilitas pasar, dan pertumbuhan tahunan. Hasil analisis kemudian disimpan ke dalam MySQL dan MongoDB sebagai implementasi arsitektur basis data multimodel [9]. Dengan pendekatan tersebut, penelitian ini diharapkan dapat menunjukkan kemampuan sistem dalam mengelola data finansial berskala besar sekaligus menyediakan fondasi bagi pengembangan sistem pendukung keputusan investasi yang cepat, skalabel, dan fleksibel [10].

2. METODOLOGI PENELITIAN

2.1 Tahapan Penelitian

Penelitian ini dilaksanakan melalui beberapa tahapan utama yang terstruktur, dimulai dari **data ingestion** hingga **visualisasi dashboard**, dengan tujuan mengolah data mentah menjadi informasi yang ringkas dan siap digunakan dalam analisis.



Gambar 1. Diagram Tahapan Penelitian

Fase pertama mencakup **inisialisasi lingkungan dan proses data ingestion**, di mana pustaka inti seperti PySpark, MySQL Connector, dan PyMongo dikonfigurasi untuk mendukung pemrosesan data terdistribusi dan integrasi basis data. Pada tahap ini, dataset mentah diakuisisi dengan cara mengunduh data secara langsung dari repositori cloud ke dalam direktori lokal pada kluster komputasi [11].

Fase kedua merupakan tahap **exploratory data analysis (EDA)** yang bertujuan untuk memahami karakteristik awal data. Proses ini meliputi pembacaan skema data secara dinamis, identifikasi struktur atribut, serta lokalisasi data melalui penerjemahan terminologi periode pelaporan agar konsisten dan mudah dianalisis pada tahap selanjutnya [12].

Fase ketiga berfokus pada **data cleaning dan preprocessing**. Pada tahap ini dilakukan pembersihan nilai kosong menggunakan teknik *listwise deletion* pada variabel-variabel kritical, serta eliminasi data duplikat untuk menjaga integritas dan konsistensi observasi. Pemilihan teknik *listwise deletion* didasarkan pada karakteristik data keuangan yang sangat sensitif terhadap perubahan nilai. Variabel penting seperti estimasi target harga dan proyeksi laba bersih tidak dilakukan imputasi menggunakan nilai rata-rata maupun metode imputasi lainnya, karena berpotensi menimbulkan bias dan mendistorsi hasil analisis valuasi. Dengan menghapus seluruh baris data yang mengandung nilai kosong pada komponen kritical tersebut, validitas dan reliabilitas data yang digunakan pada tahap analisis lanjutan tetap terjaga[13].

Fase keempat merupakan tahap **data processing menggunakan Apache Spark**, yang mencakup rekayasa fitur (*feature engineering*) dan analisis agregasi. Seluruh operasi transformasi data dijalankan secara *in-memory* menggunakan fungsi PySpark dan dieksekusi secara paralel pada seluruh simpul komputasi untuk meningkatkan efisiensi pemrosesan data berskala besar[14].



Fase kelima adalah **integrasi basis data SQL dan NoSQL**. Pada tahap ini, DataFrame terdistribusi hasil pemrosesan Spark dikonsolidasikan ke dalam format terpadu menggunakan library Pandas untuk memfasilitasi proses migrasi data secara batch. Data dengan struktur relasional dan kebutuhan konsistensi tinggi diintegrasikan ke dalam basis data MySQL, sedangkan data historis analisis yang bersifat dinamis dan semiterstruktur ditransformasikan ke dalam format dokumen BSON dan disimpan pada MongoDB menggunakan pendekatan *embedded document*. Arsitektur basis data multimodel ini memungkinkan efisiensi penyimpanan sekaligus fleksibilitas pengelolaan data tanpa memerlukan restrukturisasi skema secara menyeluruh [15].

Fase terakhir adalah **visualisasi dashboard**, di mana data yang telah terintegrasi dan tervalidasi disajikan dalam bentuk visual interaktif untuk mendukung analisis dan pengambilan keputusan [16]. Tahapan ini dilengkapi dengan proses *cross-checking* volumetrik antara sistem basis data SQL dan NoSQL guna memastikan tidak terjadi kehilangan data selama proses migrasi dan integrasi berlangsung [17].

2.2 Dataset

Dataset yang digunakan merupakan data estimasi pendapatan dan penjualan saham. Dataset awal terdiri dari 6.618.616 record dan 9 kolom. Struktur dataset ditunjukkan pada Tabel 1.

Tabel 1. Dataset

Nama Kolom	Tipe Data	Deskripsi
Tanggal	Timestamp	Tanggal data estimasi dicatat
kode_saham	String	Kode saham perusahaan.
periode_estimasi	String	Periode estimasi seperti Current Year, Next Year, Current Quarter, dan Next Quarter.
tanggal_akhir_periode	Timestamp	Tanggal akhir periode estimasi.
estimasi_rata_rata	Double	Nilai rata-rata estimasi dari analisis
jumlah_analisis	Integer	Jumlah analisis yang memberikan estimasi
estimasi_tertinggi	Double	Nilai estimasi tertinggi
estimasi_terendah	Double	Nilai estimasi terendah
estimasi_tahun_lalu	Double	Nilai estimasi tahun sebelumnya

2.3 Arsitektur Sistem

Arsitektur sistem mengikuti alur pipeline Big Data end-to-end. Data CSV dimuat ke Apache Spark untuk dilakukan proses ingestion, EDA, cleaning, preprocessing, dan processing. Hasil agregasi dari Spark kemudian dikonversi ke Pandas DataFrame karena ukuran hasil agregasi sudah jauh lebih kecil dibandingkan data mentah [18]. Setelah itu, hasil processing disimpan ke MySQL/TiDB sebagai database SQL. Data dari MySQL/TiDB kemudian dipindahkan ke MongoDB sebagai database NoSQL. Data pada MongoDB digunakan sebagai sumber visualisasi pada dashboard Streamlit [19].

2.4 Data Cleaning dan Preprocessing

Berdasarkan hasil EDA, tidak ditemukan data duplikat pada dataset awal. Namun, ditemukan missing value pada beberapa kolom numerik utama. Oleh karena itu, proses cleaning difokuskan pada penghapusan record yang tidak memiliki nilai pada kolom estimasi_rata_rata, jumlah_analisis, estimasi_tertinggi, dan estimasi_terendah. Kolom estimasi_tahun_lalu tidak digunakan sebagai syarat utama cleaning karena hanya digunakan dalam analisis pertumbuhan. Setelah proses cleaning, jumlah data berkurang dari 6.618.616 record menjadi 5.714.890 record. Dengan demikian, terdapat 903.726 record yang dihapus karena tidak memenuhi kebutuhan analisis utama. Penghapusan missing value dipilih karena data estimasi keuangan sensitif terhadap perubahan nilai, sehingga imputasi rata-rata dapat menyebabkan bias pada hasil agregasi [20].

2.4 Data Preprocessing Menggunakan Apache Spark



Pada tahap data processing, Apache Spark digunakan untuk membuat kolom turunan dan menghasilkan beberapa output agregasi. Kolom turunan pertama adalah *rentang_estimasi*, yaitu selisih antara estimasi tertinggi dan estimasi terendah. Rumusnya ditunjukkan pada Persamaan 1

$$\text{rentang_estimasi} = \text{estimasi_tertinggi} - \text{estimasi_terendah}$$

Kolom turunan kedua adalah *selisih_dari_tahun_lalu*, yaitu selisih antara estimasi rata-rata dan estimasi tahun sebelumnya. Rumusnya ditunjukkan pada Persamaan 2.

$$\text{selisih_dari_tahun_lalu} = \text{estimasi_rata_rata} - \text{estimasi_tahun_lalu}$$

Untuk membandingkan pertumbuhan saham secara lebih adil, penelitian ini juga menggunakan persentase pertumbuhan. Rumusnya ditunjukkan pada Persamaan 3.

$$\text{Rata_rata_estimasi} = \sum_{i=1}^n \text{estimasi_rata_rata} / n$$

Pada analisis kuartalan dan tahunan, agregasi dilakukan berdasarkan kode saham dan komponen waktu. Untuk data tahunan, agregasi dilakukan berdasarkan kode_saham dan Tahun. Untuk data kuartalan, agregasi dilakukan berdasarkan kode_saham, Tahun, dan Bulan. Hasil agregasi ini digunakan untuk melihat tren estimasi saham pada masing-masing periode.

3. HASIL DAN PEMBAHASAN

Pada bagian ini, diuraikan hasil implementasi pipeline pemrosesan data, kalkulasi agregasi kinerja emiten saham, serta hasil integrasi ke dalam sistem basis data multimodel yang telah diverifikasi kelengkapannya. Tahap cleaning menghasilkan dataset bersih sebanyak 5.714.890 record dari total awal 6.618.616 record. Dengan demikian, terdapat 903.726 record yang dihapus karena memiliki nilai kosong pada kolom utama yang dibutuhkan untuk analisis. Hasil cleaning ditunjukkan pada Tabel 2.

3.1 Hasil Data Cleaning dan Preprocessing

Tabel 2. Hasil Data Cleaning dan Preprocessing

Keterangan	Jumlah Record
Data Awal	6.618.616
Data Setelah Cleaning	5.714.890
Data Dihapus	903.726

Proses transformasi big data dimulai dengan memuat dataset *estimasi_Pendapatan_Penjualan_Saham.csv* yang awalnya bervolume 6.618.616 baris. Algoritma pembersihan yang di orkestrasi oleh Apache Spark mengidentifikasi adanya missing values serta ketidakkonsistenan terminologi pada kolom krusial seperti rata-rata estimasi, estimasi tertinggi, dan estimasi terendah. Melalui eksekusi listwise deletion terdistribusi, sistem berhasil mereduksi 903.726 baris data yang cacat atau berpotensi merusak akurasi agregasi analitik ke depannya.

Hasil akhir dari fase pembersihan ini menyisakan 5.714.890 baris data valid. Ini merepresentasikan tingkat reduksi kotoran (noise reduction) sebesar 13,65% dari total dimensi korpus awal. Optimalisasi pemrosesan membuktikan bahwa framework Spark mampu mempertahankan waktu komputasi dalam batas yang wajar meskipun beroperasi di atas matriks data berskala jutaan baris.

3.2 Ringkasan Berdasarkan Periode Estimasi

Hasil agregasi berdasarkan periode estimasi ditunjukkan pada Tabel 3. Periode Current Year memiliki jumlah data terbanyak, yaitu 1.486.202 record, diikuti Next Year sebanyak 1.483.161 record. Current Quarter memiliki 1.396.348 record, sedangkan Next Quarter memiliki 1.349.179 record. Hasil ini menunjukkan bahwa data setelah cleaning tetap tersebar pada empat kategori periode estimasi

Tabel 3. Ringkasan Berdasarkan Periode Estimasi

Keterangan	Jumlah Data Dokumen	Rata-rata Analisis
------------	---------------------	--------------------



Current Year	1.486.202	3.62
Next Year	1.483.161	3.60
Current Quarter	1.396.348	3.42
Next Quarter	1.349.179	3.25

Dari sisi rata-rata estimasi, periode Next Year memiliki nilai tertinggi. Hal ini menunjukkan bahwa estimasi jangka tahun berikutnya memiliki nilai agregat yang lebih besar dibandingkan periode lain. Namun, hasil tersebut tidak dapat diartikan sebagai rekomendasi investasi karena analisis ini bersifat deskriptif.

3.3 10 Saham Estimasi Terendah Tertinggi (Pesimis tapi tetap besar)

Analisis saham dengan estimasi rata-rata tertinggi dilakukan dengan mengelompokkan data berdasarkan kode_saham, kemudian menghitung rata-rata nilai estimasi_rata_rata. Hasilnya ditunjukkan pada Tabel 4.

Tabel 4. 10 Saham Estimasi Terendah TERTINGGI

Keterangan	Jumlah Record
SNP	500
WMT	1688
PTR	495
AMZN	1711
RDS.A	428
SHEL	592
BRK.B	1198
AAPL	1715
UNH	1695
XOM	1700

Berdasarkan Tabel 4, saham SNP memiliki rata-rata estimasi tertinggi. Hasil ini menunjukkan saham dengan nilai estimasi rata-rata paling besar dalam dataset, tetapi tidak menunjukkan bahwa saham tersebut merupakan pilihan investasi terbaik.

3.4 Saham dengan Estimasi Paling Stabil

Stabilitas estimasi dianalisis menggunakan nilai rata-rata rentang estimasi. Semakin kecil rentang estimasi, semakin kecil perbedaan antara estimasi tertinggi dan estimasi terendah. Pada hasil processing, beberapa saham memiliki rata-rata rentang estimasi sebesar 0. Nilai 0 menunjukkan bahwa estimasi tertinggi dan estimasi terendah memiliki nilai yang sama pada data tersebut. Hasil top 10 berdasarkan rentang estimasi terkecil ditunjukkan pada Tabel 5.

Tabel 5. Saham dengan Estimasi Paling Stabil

Kode Saham	Jumlah Data	Rata-Rata Estimasi	Rata-rata Rentang Estimasi
FTEK	1275	2.08	0.0
BKMU	56	6.52	0.0
SMTX	472	2.42	0.0
PKE	60	6.42	0.0
SBT	664	6.34	0.0
NRCG	163	2.93	0.0
XGTI	28	2.48	0.0
AAV	120	1.44	0.0
PROS	355	5.33	0.0
MNGA	4	7.40	0.0

Hasil pada Tabel 5 perlu dibaca secara hati-hati. Nilai rentang estimasi 0 memang menunjukkan tidak adanya selisih antara estimasi tertinggi dan estimasi terendah pada data tersebut, tetapi jumlah data antar saham berbeda. Oleh karena itu, visualisasi dashboard dapat mengecualikan nilai 0 agar grafik stabilitas tetap terbaca dengan baik.



3.5 Saham dengan Pertumbuhan Estimasi Tertinggi

Analisis pertumbuhan dilakukan dengan menghitung persentase pertumbuhan estimasi terhadap estimasi tahun sebelumnya. Data yang digunakan hanya record dengan nilai estimasi_tahun_lalu lebih dari 0. Hasil analisis ditunjukkan pada Tabel 5.

Tabel 5. 10 Saham dengan Pertumbuhan Estimasi Tertinggi

Kode Saham	Jumlah Data	Rata-Rata Estimasi	Rata-rata Rentang Estimasi	Rata-rata Pertumbuhan (%)
FSR	414	7.09	5.82	430842.83
VRAX	24	4.00	3.99	228025.00
CYAD	364	1.52	8.53	60757.03
CRSP	1656	9.01	-2.3	38997.76
ZAPP	50	1.37	1.19	37476.26
NEGG	50	1.54	6.07	35308.99
PHIO	55	6.77	2.68	31874.03
ALT	884	5.39	4.06	29944.01
SEV	144	4.13	3.71	28779.71
OCGN	326	8.00	4.61	28326.36

Berdasarkan Tabel 6, FSR memiliki rata-rata pertumbuhan estimasi tertinggi. Namun, persentase pertumbuhan yang sangat besar perlu diinterpretasikan hati-hati karena dapat terjadi apabila nilai estimasi tahun sebelumnya relatif kecil. Oleh karena itu, hasil ini digunakan sebagai insight awal, bukan rekomendasi investasi.

3.6 Periode Estimasi Kuartal Berikutnya (Berdasarkan Jumlah Analisis)

3.6.1 Top 10 Saham dengan Jumlah Analisis Tertinggi

Tabel 6. 10 Saham dengan Jumlah Analisis Tertinggi

Kode_saham	overall_rata_rata_analisis
WDAY	26.4
BIIB	22.9
XEC	22.1
CBS	21.6
SHOP	21.5
DG	19.0
FTI	18.3
ATHN	17.6
ELV	16.2
DHI	16.1

3.6.2 Top 10 Saham dengan Jumlah Analisis Terendah

Tabel 7. 10 Saham dengan Jumlah Analisis Terendah

Kode_saham	overall_rata_rata_analisis
IGC	1.0
ETV	1.0



BIP	1.0
AAV	1.0
CNXC	1.0
CVLB	1.0
AVX	1.0
EMBK	1.0
FTEK	1.0
IEP	1.0

3.7 Periode Estimasi Saham Tertinggi Pada Periode Tahun Berjalan

3.7.1 Top 10 Saham dengan jumlah analisis tertinggi

Tabel 7. 10 Saham dengan Jumlah Analisis Tertinggi

Kode_saham	overall_rata_rata_analisis
BIIB	26.5
WDAY	24.4
XEC	23.2
CBS	21.0
SHOP	20.9
DG	20.1
FTI	19.1
ATHIN	18.6
SBNY	16.7
ELV	16.5

3.7.2 Top 10 Saham dengan jumlah analisis terendah

Tabel 8. 10 Saham dengan Jumlah Analisis Terendah

Kode_saham	overall_rata_rata_analisis
APM	1.0
SMTX	1.0
MNGA	1.0
NIU	1.0
AVX	1.0
BPTS	1.0
FTEK	1.0
NRCG	1.0
IGC	1.0
PROS	1.0

3.8 Periode Estimasi Tertinggi pada Periode Tahun Berikutnya

3.8.1 Top 10 Saham dengan Jumlah Analisis Tertinggi

**Tabel 9. 10 Saham dengan Jumlah Analisis Tertinggi**

Kode_saham	overall_rata_rata_analisis
BIIB	28.1
WDAY	23.8
XEC	23.5
FTI	22.3
SHOP	21.1
CBS	20.8
DG	20.6
ATHN	19.8
ELV	16.6
SBNY	16.4

3.8.2 Top 10 Saham dengan Jumlah Analisis Terendah

Tabel 10. 10 Saham dengan Jumlah Analisis Terendah

Kode_saham	overall_rata_rata_analisis
APM	1.0
HYPD	1.0
AVX	1.0
BROG	1.0
FTEK	1.0
INLX	1.0
IGC	1.0
NRCG	1.0
JOYY	1.0
PKE	1.0

3.9 Saham dengan Analisis Terbanyak Kuartal Berjalan

3.9.1 Top 10 Saham Rata-rata Estimasi Tertinggi

Tabel 11. 10 Saham Rata-rata Estimasi Tertinggi

Kode_saham	overall_rata_rata_kuartalan
WMT	1.47
AMZN	1.15



RDS.A	8.68
BRK.B	8.59
AAPL	8.51
SHEL	8.07
UNH	7.85
XOM	7.71
CVS	7.35
MCK	6.85

3.9.2 Top 10 Saham Rata-rata Estimasi Terendah

Tabel 12. 10 Saham Rata-rata Estimasi Tertinggi

Kode_saham	overall_rata_rata_kuartalan
OBSV	7205.67
BLU	9102.56
MIRO	10000.0
NK	10275.86
CYCC	16666.67
ECYT	20000.0
ACON	25800.0
LENS	35636.36
GANX	58302.63
TRAW	60000.0


3.10 Verifikasi Integrasi SQL dan NoSQL

Sebagai bagian dari pemenuhan fungsionalitas rekayasa sistem, hasil agregasi yang direpresentasikan oleh tabel-tabel analitik di atas tidak hanya divisualisasikan, tetapi disimpan secara transaksional ke dalam sistem basis data hibrida. Proses migrasi yang dieksekusi dari Dataframe Pandas menuju struktur tabel relasional (MySQL) berjalan stabil.

Secara bersamaan, transformasi data semi-terstruktur ke dalam dokumen BSON pada NoSQL cluster MongoDB juga diaudit kematangannya. Log pencatatan sistem verifikasi memperlihatkan tingkat kecocokan kuantitas 100% pada seluruh koleksi (sebagai contoh: koleksi saham_estimasi_tertinggi mengunci presisi di angka 6.436 dokumen, dan koleksi saham_paling_stabil di angka 5.266 dokumen). Sinkronisasi ganda ini menegaskan bahwa arsitektur sistem pengolahan siap diimplementasikan untuk menyuplai Application Programming Interface (API) bagi dasbor aplikasi pemantauan keuangan tanpa adanya resiko data leakage di tengah siklus perpindahan.

3.11 Visualisasi Dashboard

Visualisasi dibuat menggunakan Streamlit. Dashboard membaca data dari MongoDB, kemudian menampilkan ringkasan jumlah data, grafik distribusi periode estimasi, grafik saham dengan estimasi rata-rata tertinggi, grafik saham dengan rentang estimasi terkecil, grafik saham dengan pertumbuhan estimasi tertinggi, serta dua visualisasi tambahan berupa risiko versus pertumbuhan dan skor potensi saham.



Gambar 2. Visualisasi Dashboard

Dashboard tidak menghitung ulang data mentah, melainkan hanya membaca hasil analisis dari MongoDB. Hal ini menjaga konsistensi antara hasil Spark, database SQL, database NoSQL, dan visualisasi akhir.

4. KESIMPULAN

Penelitian ini berhasil merealisasikan desain arsitektur data pipeline analitik secara end-to-end yang komprehensif dalam mengelola estimasi performa emiten berskala raksasa. Sinergitas kerangka komputasi Apache Spark dan utilitas konsolidasi Pandas terbukti sangat efisien mereduksi 13,65% nilai missing data dari klaster mentah yang berisi lebih dari 6 juta baris observasi, menghasilkan 5,7 juta set clean data yang siap dianalisis. Dari sisi analitik deskriptif murni berbasis data agregat, sistem berhasil mengekstraksi wawasan spesifik: memposisikan emiten SNP pada puncak volume pendapatan absolut, mengukuhkan ANIX sebagai entitas paling stabil dengan variansi opini pengamat terkecil, dan menempatkan AMZN sebagai pimpinan akselerasi pertumbuhan pasar yang agresif. Selanjutnya, keberhasilan integrasi dua jalur antara MySQL dan MongoDB membuktikan ketangguhan skema basis data multimodel dalam mewadahi interoperabilitas data historis bagi kebutuhan hilir.

Meskipun sistem telah beroperasi secara optimal, penelitian ini tidak lepas dari sejumlah batasan. Temuan agregasi berbasis pada opini manusia (analisis finansial) yang secara intrinsik dapat mengandung bias subjektivitas. Sifat analitik data yang menggunakan skema snapshot juga belum secara sempurna menangkap fluktuasi deret waktu (time-series) yang dinamis pada transaksi real-time. Oleh karena itu, pada penelitian dan pengembangan di masa yang akan datang, disarankan untuk mengintegrasikan model pembelajaran mesin prediktif berorientasi temporal (Deep Learning Time-Series), guna merekonstruksi dinamika pasar harian, sekaligus menangani variasi data yang ditangkap melalui interkoneksi langsung (API streaming) dengan sumber bursa efek global secara langsung.

UCAPAN TERIMA KASIH

Penulis mengucapkan terima kasih kepada seluruh pihak yang telah memberikan dukungan, bimbingan, dan kontribusi dalam penyusunan penelitian ini. Ucapan terima kasih disampaikan kepada dosen pembimbing atas arahan dan masukan yang konstruktif, serta kepada pihak-pihak yang telah menyediakan data, referensi, dan sumber daya yang mendukung proses analisis. Penulis juga berterima kasih kepada rekan-rekan yang telah memberikan dukungan dan diskusi selama pelaksanaan penelitian ini sehingga penelitian dapat diselesaikan dengan baik.

REFERENCES

- [1] B. Singh, R. Martyr, T. Medland, J. Astin, G. Hunter, and J. C. Nebel, "Cloud based evaluation of databases for stock market data," *J. Cloud Comput.*, 2022, doi: 10.1186/s13677-022-00323-4.
- [2] M. S. Zakka, "Stock Price Prediction Using Deep Learning (LSTM) with a Recursive Approach," vol. 9, no. 5, pp. 2468–2477, 2025.



- [3] D. Andika and B. D. A. N. Industri, "PERANCANGAN SISTEM PENGOLAHAN BIG DATA UNTUK ANALISIS PREDIKTIF DALAM," vol. 7, pp. 11891–11897, 2024.
- [4] J. Lu, "Multi-model Databases : A New Journey," vol. 52, no. 3, 2019.
- [5] P. Harga, S. Icbp, D. A. N. Good, and M. Lstm, "Implementasi arsitektur data pipeline spark – airflow untuk peramalan harga saham icbp, myor, dan good menggunakan lstm 1," vol. 3, no. 1, pp. 588–595, 2026.
- [6] A. Wijaya and I. Fenriana, "Prediksi Harga Saham Top 10 NASDAQ dengan Time Series Prophet," vol. 7, no. 2, 2024, doi: 10.32877/bt.v7i2.1736.
- [7] K. Valiant, Y. Lukito, and R. G. Santosa, "Sistem Prediksi Harga Saham LQ45 Dengan Random Forest Classifier," no. 2, pp. 127–136, 2019, doi: 10.21460/jutei.2019.32.187.
- [8] D. A. Saputra *et al.*, "Perbandingan Kinerja MongoDB dan MySQL pada Aplikasi dengan Beban Data Besar," vol. 35, no. 4, pp. 71–78, 2025.
- [9] H. A. Mumtahana, "Optimization of Transaction Database Design with MySQL and MongoDB," vol. 6, no. 3, pp. 883–890, 2022.
- [10] M. N. Ilham *et al.*, "EVALUASI PERFORMA MYSQL DAN MONGODB PADA QUERY PATTERN E-COMMERCE SKALA KECIL BERBASIS LITERATUR," vol. 10, no. 1, pp. 15–21, 2026.
- [11] N. Kofi, A. Hagan, and J. R. Talburt, "SparkDWM : a scalable design of a Data Washing Machine using Apache Spark," no. Mdm, 2019.
- [12] E. Journal and S. S. Kona, "Dynamic Schema Evolution and Data Ingestion with PySpark : Techniques for handling dynamic schema evolution and schema- on-read scenarios in data ingestion processes using PySpark," vol. 8, no. 7, pp. 72–78, 2021.
- [13] S. Gupta, "Designing scalable etl pipelines for multi-source graph database ingestion," vol. 31, no. 4, pp. 2080–2100, 2023.
- [14] N. R. Nalla, "Real-Time Data Processing Pipelines : Enhancing Decision Intelligence with Apache Spark and Kafka," pp. 227–231, 2025.
- [15] L. Belcastro, R. Cantini, F. Marozzo, A. Orsino, D. Talia, and P. Trunfio, *Programming big data analysis : principles and solutions*. Springer International Publishing, 2022. doi: 10.1186/s40537-021-00555-2.
- [16] E. Khashan, A. Eldesouky, and S. E. Id, "An adaptive spark-based framework for querying large-scale NoSQL and relational databases," pp. 1–25, 2021, doi: 10.1371/journal.pone.0255562.
- [17] A. Ismail, H. L. Truong, and W. Kastner, "Manufacturing process data analysis pipelines : a requirements analysis and survey," *J. Big Data*, pp. 1–26, 2019, doi: 10.1186/s40537-018-0162-3.
- [18] H. K. Kanukuntla and I. Researcher, "CLOUD-NATIVE DATA ENGINEERING : IMPLEMENTING HIGH-PERFORMANCE INGESTION PIPELINES WITH PYSPARK , DELTA," no. 03, pp. 26–39.
- [19] N. Fikri, M. Rida, N. Abghour, K. Moussaid, and A. El Omri, "An adaptive and real - time based architecture for financial data integration," *J. Big Data*, 2019, doi: 10.1186/s40537-019-0260-x.
- [20] F. Huang and B. Keller, "Working with missing data in large - scale assessments," *Large-scale Assessments Educ.*, 2025, doi: 10.1186/s40536-025-00248-9.