

# Pengembangan Sistem Big Data

## untuk Analisis Earnings & Sales Estimate Saham



Apache Spark · MySQL / TiDB · MongoDB · Streamlit

---

Kelompok 02 – D4 Teknologi Rekayasa Perangkat Lunak  
Fakultas Vokasi | Institut Teknologi Del

# Tim Kelompok 02

## Pembagian Tugas & Presenter

|   |          |                             |                                         |
|---|----------|-----------------------------|-----------------------------------------|
| 1 | 11423051 | Erwin Jeremy Sianturi       | Latar Belakang, Dataset & Tujuan        |
| 2 | 11423026 | Flora Nainggolan            | Data Ingestion & Apache Spark Setup     |
| 3 | 11423024 | Fernando Yosia Parhusip     | Data Cleaning & Processing              |
| 4 | 11423031 | Febri Sweeta Br Lumban Raja | Integrasi SQL & NoSQL                   |
| 5 | 11423041 | Dewa Armada Gurusinga       | Query Analysis, Visualisasi & Dashboard |

# Latar Belakang



Data pasar saham terus berkembang pesat, termasuk data earnings & sales estimate yang mencerminkan proyeksi kinerja perusahaan.



Dataset proyek ini berisi 6.618.616 record — jauh di atas batas minimum Big Data (100.000 record).



Pengolahan secara manual atau konvensional tidak efektif untuk data sebesar ini; diperlukan teknologi Big Data.



Apache Spark dipilih karena kemampuannya memproses data skala besar secara efisien dan terdistribusi.

## Dataset Proyek

**6.618.616**

Record Awal

**5.714.890**

Setelah Cleaning

**903.726**

Record Dihapus

# Tujuan Proyek



## Data Pipeline

Membangun pipeline Big Data end-to-end: ingestion → cleaning → processing → storage → visualisasi.



## Visualisasi

Menyajikan hasil analisis dalam dashboard Streamlit yang interaktif dan mudah dipahami.



## Integrasi DB

Mengintegrasikan database SQL (MySQL/TiDB) dan NoSQL (MongoDB) untuk penyimpanan fleksibel.



## Bukan Rekomendasi Investasi

Sistem berfungsi sebagai alat bantu eksplorasi data, bukan pemberi saran investasi langsung.



## Analisis Data

Menghasilkan insight: saham estimasi tertinggi, paling stabil, dan pertumbuhan tertinggi.

# Dataset




*Estimasi Pendapatan & Penjualan Saham — 9 Kolom, 6.618.616 Record Awal*

| Nama Kolom            | Tipe Data       | Deskripsi                                        |
|-----------------------|-----------------|--------------------------------------------------|
| Tanggal               | DateTime        | Tanggal data dicatat atau dipublikasikan         |
| kode_saham            | String          | Kode saham perusahaan (contoh: AMZN, AAPL)       |
| periode_estimasi      | String          | Periode estimasi: Current/Next Quarter atau Year |
| tanggal_akhir_periode | DateTime        | Tanggal akhir periode laporan keuangan           |
| estimasi_rata_rata    | Numerik (Float) | Rata-rata estimasi dari seluruh analisis         |
| jumlah_analisis       | Integer         | Jumlah analisis yang memberikan estimasi         |
| estimasi_tertinggi    | Numerik (Float) | Nilai estimasi tertinggi dari analisis           |
| estimasi_terendah     | Numerik (Float) | Nilai estimasi terendah dari analisis            |
| estimasi_tahun_lalu   | Numerik (Float) | Nilai aktual/estimasi periode sama tahun lalu    |



# Arsitektur Sistem



Alur data: CSV → Spark (cleaning & processing) → MySQL/TiDB (SQL) → MongoDB (NoSQL) → Dashboard Streamlit

# Data Ingestion & Apache Spark Setup

1 Membuat SparkSession sebagai titik masuk utama Apache Spark

2 Dataset CSV diunduh dari Google Drive ke direktori Google Colab

3 Data dibaca langsung ke Spark DataFrame

4 Spark versi 4.0.2 berhasil diinisialisasi (SparkSession berhasil dibuat)

## Code Snippet

```
# Membuat SparkSession sebagai mesin ut
from pyspark.sql import SparkSession

spark = SparkSession.builder \
    .appName("BigDataProject") \
    .getOrCreate()
print("SparkSession berhasil dibuat")
print(spark.version)

... SparkSession berhasil dibuat
4.0.2
```

# Exploratory Data Analysis (EDA)



## Informasi Dasar

6.618.616 record, 9 kolom. Kolom numerik bertipe double, tanggal masih string.



## Missing Value

jumlah\_analis, estimasi\_tertinggi & terendah: 903.726 nilai kosong. Kolom identitas: 0 missing.



## Data Duplikat

Tidak ada duplikat. Data unik = 6.618.616 (100% unik).



## Statistik Deskriptif

Nilai estimasi sangat bervariasi. Max: 2.38E12. Nilai negatif valid (estimasi kerugian).



## Distribusi Periode

Setiap periode (CQ, NQ, CY, NY) memiliki 1.654.654 record — distribusi seimbang.




## Histogram & Boxplot

Distribusi right-skewed. Outlier tidak dihapus (perusahaan besar vs kecil).



# Pemeriksaan Data – Missing Value & Duplikat



## ✓ Tidak Ada Duplikat

Data awal = Data unik  
= 6.618.616 record  
(0 duplikat ditemukan)

## ⚠ Nilai Tidak Logis

Tidak ada kasus:

- estimasi\_tertinggi < estimasi\_terendah
- jumlah\_analis negatif

Nilai negatif pada kolom lain  
valid (estimasi kerugian).

# Data Cleaning & Preprocessing

6.618.616

Data Awal

5.714.890

Data Setelah Cleaning

903.726

Record Dihapus

## 1 Hapus Missing Value:

Kolom wajib: Tanggal, kode\_saham, periode\_estimasi, tanggal\_akhir\_periode, estimasi\_rata\_rata, jumlah\_analis, estimasi\_tertinggi, estimasi\_terendah.

## 2 Konversi Tipe Data:

Kolom Tanggal & tanggal\_akhir\_periode dikonversi ke tipe timestamp menggunakan format 'M/d/yy h:mm a'.

## 3 Cast Integer:

Kolom jumlah\_analis diubah dari string menjadi tipe integer untuk keperluan analisis numerik.

## 4 estimasi\_tahun\_lalu:

Tidak dijadikan syarat utama cleaning — hanya dibutuhkan untuk analisis pertumbuhan (opsional).

# Data Processing – Pembuatan Kolom Analisis



Apache Spark · df\_clean (5.714.890 record) sebagai input



rentang\_estimasi

Formula:

```
estimasi_tertinggi - estimasi_terendah
```

Kegunaan:

Mengukur tingkat stabilitas estimasi suatu saham. Semakin kecil nilai, semakin konsisten pandangan analis.



selisih\_dari\_tahun\_lalu

Formula:

```
estimasi_rata_rata - estimasi_tahun_lalu
```

Kegunaan:

Mengukur perubahan estimasi dibandingkan periode yang sama tahun sebelumnya.

## Output DataFrame Hasil Processing:

- df\_processed — data bersih + kolom analisis baru
- df\_period — ringkasan per periode estimasi
- df\_top — saham estimasi tertinggi
- df\_stable — saham paling stabil
- df\_growth — saham pertumbuhan tertinggi

# Data Processing – Hasil Agregasi & Analisis


## Ringkasan per Periode Estimasi

| Periode         | Jumlah Data | Rata-rata Estimasi |
|-----------------|-------------|--------------------|
| Current Year    | 1.486.202   | 7,09 Miliar        |
| Next Year       | 1.483.161   | 7,52 Miliar        |
| Current Quarter | 1.396.348   | 1,71 Miliar        |
| Next Quarter    | 1.349.179   | 1,75 Miliar        |

## Top Saham – Estimasi Rata-rata Tertinggi (Seluruh Periode)

- SNP (~404,7 M)
- WMT (~374,1 M)
- PTR (~349,7 M)
- AMZN (~306,0 M)
- RDS.A (~272,2 M)

## Top Pertumbuhan Estimasi (% YoY)



# Integrasi Database SQL – MySQL / TiDB Cloud

1

## Konfigurasi Koneksi

Parameter: host, port, username, password, db-name untuk TiDB Cloud. Fungsi `create_db_connection()` via `mysql.connector`.

2

## Pembuatan Tabel Otomatis

Normalisasi nama tabel (lowercase + underscore). `DROP TABLE IF EXISTS` untuk memastikan data terbaru. Auto-mapping tipe: `int`→`BIGINT`, `float`→`DOUBLE`, `datetime`→`DATETIME`, lain→`TEXT`.

3

## Penyimpanan Data

`INSERT INTO` menggunakan `executemany()` — efisien untuk penyisipan batch. Commit setelah semua data tersimpan.

4

## Tabel Tersimpan

4 tabel: `ringkasan_periode_estimasi`, `saham_estimasi_tertinggi`, `saham_paling_stabil`, `saham_pertumbuhan_tertinggi`.

## Tabel di TiDB Cloud



`growth_stocks`



`period_summary`



`ringkasan_periode_estimasi`



`saham_estimasi_tertinggi`



`saham_paling_stabil`



`saham_pertumbuhan_tertinggi`



`stable_stocks`



`top_consensus`



SQL Editor BETA

SchemasSQL Files

Search

> 

sys

> 

test

> 

growth\_stocks

> 

period\_summary

> 

ringkasan\_periode\_estimasi

> 

saham\_estimasi\_tertinggi

> 

saham\_paling\_stabil

> 

saham\_pertumbuhan\_tertinggi

> 

stable\_stocks

> 

top\_consensus

New query

Auto Saved ✓ 

test

Run

Explain

1

/\* Enter "USE {database};" to start exploring your data.

2

Press Ctrl + I to try out AI-generated SQL queries or SQL rewrite using Chat2Query. \*/

3

USE test;

4

SELECT \* FROM growth\_stocks

5

ResultChart

| kode_saham | avg(pertumbuhan_dari_tahun_lalu) |
|------------|----------------------------------|
| AMZN       | 3.958684365781711e+10            |
| SNP        | 3.539919213973799e+10            |
| PTR        | 2.0448724832214764e+10           |
| GOOG       | 1.8603632508833923e+10           |
| SUNC       | 1.838e+10                        |
| GOOGL      | 1.751142603550296e+10            |
| UNH        | 1.6636032028469751e+10           |
| MSFT       | 1.3922809721398932e+10           |
| AAPL       | 1.235639035861258e+10            |
| META       | 1.1756144578313251e+10           |
| NVDA       | 1.1465667848699764e+10           |

showing 500 rows out of 6337 from database test

[Gambar: Screenshot SQL Editor TiDB Cloud – Tabel & Query Result]

# Integrasi NoSQL – MongoDB Atlas

1

## Koneksi Ganda

Koneksi ke TiDB Cloud (sumber data) dan MongoDB Atlas (tujuan) dibuat bersamaan. Ping untuk verifikasi koneksi MongoDB.

2

## Ambil Data dari SQL

SELECT \* dari setiap tabel TiDB, konversi ke Pandas DataFrame menggunakan dictionary=True untuk pasangan key-value.

3

## Simpan ke MongoDB

DataFrame dikonversi ke list of dictionaries (to\_dict orient='records'). delete\_many({}) untuk hapus duplikat, lalu insert\_many().

4

## Migrasi Otomatis

table\_mappings memetakan nama tabel SQL ke nama collection MongoDB. Seluruh data direplikasi tanpa input manual.


## Collections MongoDB

|                               |           |
|-------------------------------|-----------|
| 📁 ringkasan_periode_estimasi  | 4 docs    |
| 📁 saham_estimasi_tertinggi    | 6,4K docs |
| 📁 saham_paling_stabil         | 5,3K docs |
| 📁 saham_pertumbuhan_tertinggi | 6,3K docs |
| 📁 growth_stocks               | 6,3K docs |
| 📁 stable_stocks               | 5,3K docs |


SQL → NoSQL: struktur dokumen JSON lebih fleksibel, tidak memerlukan skema kaku.

# Hasil Analisis – Distribusi & Estimasi Tertinggi

Distribusi Periode Estimasi



Top 10 Saham – Estimasi Tertinggi (Miliar)




**Insight:** Distribusi periode seimbang (~25% masing-masing). SNP memimpin estimasi rata-rata tertinggi (~404,7 Miliar) — dominasi perusahaan energi & retail besar.



# Hasil Analisis – Pertumbuhan & Stabilitas Estimasi

## Top 10 Saham – Pertumbuhan Estimasi (% YoY)



## Saham Estimasi Paling Stabil

(Rata-rata rentang estimasi = 0)

✓ FTEK (1.275 data)

✓ SMTX (472 data)

✓ SBT (664 data)

✓ NRCG (163 data)

✓ PROS (355 data)

✓ VLD (418 data)




**Catatan:**

Stabilitas mengacu pada konsistensi estimasi analisis, bukan stabilitas harga saham. Saham stabil dengan data sedikit perlu dikaji lebih lanjut.


# Dashboard Streamlit – Analisis Kuartalan

## Kuartal Berjalan (Current Quarter)



- WMT memimpin (~150 Miliar)
- AMZN posisi 2 (~120 Miliar)
- RDS.A posisi 3 (~87 Miliar)
- BII.B: analisis terbanyak (27 analisis)
- WDAY: 26 analisis, SHOP: 22 analisis

## Kuartal Berikutnya (Next Quarter)



- WMT tetap memimpin (~150 Miliar)
- AMZN posisi 2 (~120 Miliar)
- BRK.B naik ke posisi 3 (~88 Miliar)
- WDAY: analisis terbanyak (26 analisis)
- XEC & CBS: 22 analisis masing-masing

## 🏆 Peringkat Top 10 Saham

Pilih Periode Top 10:

Kuartal Berjalan



Pilih Kategori Peringkat:

Estimasi Tertinggi (Top 10)



### Estimasi Tertinggi (Top 10) - Kuartal Berjalan



Pilih Periode Top 10:

Kuartal Berikutnya


Pilih Kategori Peringkat:

Estimasi Tertinggi (Top 10)

Estimasi Tertinggi (Top 10) - Kuartal Berikutnya



# Dashboard Streamlit – Analisis Tahunan & Skor Potensi



|  Skor Potensi |      |      |
|--------------------------------------------------------------------------------------------------|------|------|
| (Estimasi × Konsensus Analisis)                                                                  |      |      |
| #1                                                                                               | AMZN | 1.37 |
| #2                                                                                               | WMT  | 1.07 |
| #3                                                                                               | CVS  | 0.87 |
| #4                                                                                               | ELV  | 0.74 |
| #5                                                                                               | AAPL | 0.67 |

 AMZN menduduki puncak Skor Potensi — keseimbangan antara nilai estimasi besar dan tingginya kepercayaan konsensus analisis. Spread risiko AMZN sangat sempit (6,8 Miliar) menandakan konsensus yang kuat.



# Kesimpulan



Pipeline Big Data end-to-end berhasil dibangun: dari 6,6 juta record mentah hingga 5,7 juta record bersih siap analisis.



Integrasi SQL (MySQL/TiDB) dan NoSQL (MongoDB) berjalan sukses, data tersimpan di kedua sistem secara otomatis.



Insight utama: SNP (estimasi tertinggi), FSR (pertumbuhan 430.842%), FTEK/VLD (estimasi paling stabil).



Dashboard Streamlit menunjukkan AMZN unggul dalam Skor Potensi — keseimbangan estimasi tinggi & konsensus analisis kuat.



Sistem ini adalah alat bantu analisis awal, bukan pemberi rekomendasi investasi langsung.

# Terima Kasih

Pertanyaan & Diskusi

---

Kelompok 02 | D4 Teknologi Rekayasa Perangkat Lunak  
Fakultas Vokasi – Institut Teknologi Del